

Super-Convergence: Very Fast Training of Neural Networks Using Large Learning Rates

Аннотация

Тезис

Статья исследует возможность применения больших learning rates для достижения сходимости за меньшее количество итераций. Увеличение learning rate также служит отдельным фактором для регуляризации модели.

Обоснование тезиса

Авторы проводили LR range test для ResNet-56 на CIFAR-10 точность оставалась высокой вплоть до $LR = 3$; на порядок выше типичных значений. Это побудило авторов экспериментировать с очень большими learning rates.

Оценка оптимального learning rate

В контексте обучения нейронной сети, вычислять гессиан неразумно. Для прогнозирования оптимального learning rate авторы предлагают применять метод, приближающий часть гессиана вдоль самого резкого спуска

$$\epsilon^* = \epsilon \frac{\theta_{i+1} - \theta_i}{2\theta_{i+1} - \theta_i - \theta_{i+2}}$$


ϵ^* - оценка оптимального learning rate

ϵ - примененный learning rate

Θ - веса модели на i -й итерации

Оценка оптимального learning rate

Оценки оптимальных LR
в диапазоне 2–6. На
порядок выше
стандартных 0.1



(a) Estimated learning rates computed from the weights at every iteration for 300 iterations.

Режим обучения 1-cycle

Стандартный режим обучения PC-LR применяет единый learning rate (~ 0.1) до выхода точности на плато и затем уменьшает его в 10 раз и повторяет итерацию до сходимости.

Авторы предлагают использовать альтернативный сценарий - 1 cycle CLR: LR range test, цикл обучения где LR линейно меняется от минимума до максимума и обратно до минимума. Далее LR снижается на несколько порядков ниже начального.

Супер-сходимость

При применении больших learning rates и альтернативного алгоритма их применения (CLR/1 cycle против PC-LR) был идентифицирован феномен, когда без изменения архитектуры такой сценарий обучения давал лучшие результаты при ускорении обучения на порядок. Наибольший прирост наблюдался на меньших наборах обучающих данных.

Супер-сходимость: CIFAR-10


# training samples	Policy (Range)	BN MAF	Total Iterations	Accuracy (%)
40,000	PC-LR=0.35	0.999	80,000	89.1
40,000	CLR (0.1-3)	0.95	10,000	91.1
30,000	PC-LR=0.35	0.999	80,000	85.7
30,000	CLR (0.1-3)	0.95	10,000	89.6
20,000	PC-LR=0.35	0.999	80,000	82.7
20,000	CLR (0.1-3)	0.95	10,000	87.9
10,000	PC-LR=0.35	0.999	80,000	71.4
10,000	CLR (0.1-3)	0.95	10,000	80.6

Table 1: Comparison of final accuracy results for various training regimes of Resnet-56 on Cifar-10. BN MAF is the value use for the *moving_average_fraction* parameter with batch normalization. PC-LR is a standard piecewise constant learning rate policy described in Section 2 with an initial learning rate of 0.35.


Большой learning rate как регуляризация

При экспериментах с ImageNet подтвердилось, что большой LR сам регуляризует обучение, поэтому остальные виды регуляризации нужно уменьшить. На ImageNet без снижения weight decay использовать большие LR не удавалось - супер-сходимость не наступала.

Супер-сходимость и регуляризация: ImageNet



(a) Resnet-50



(b) Inception-resnet-v2

Для 1cycle WD снижен с $1e-5$ до $3e-6$: большой LR сам регуляризует обучение

Выводы

В исследовании представлены примеры ранее неизвестного феномена, который авторы называют суперсходимостью. Продемонстрировано, что суперсходимость может обеспечить сравнимую или лучшую точность за на порядок меньшее число итераций, особенно в условиях ограниченных данных для обучения. Также был описан упрощенный метод без-Гессиан оптимизации для оценки оптимального learning rate.